

인공지능공학과  
12223552 서지민

# Machine Learning

통합 운전자  
위험 요소 감지 시스템

IDRS

(Integrated Driver Risk-Score)

System

인하대학교

TERM Project



인하대학교  
INHA UNIVERSITY



|                     |                        |                  |
|---------------------|------------------------|------------------|
| 문제 정의 및 연구 개요<br>01 | 데이터셋 구축 및<br>전처리<br>02 | 3-Model 비교<br>03 |
| 차별화 분석<br>04        | 배포 시나리오<br>05          | 결론 & 기여<br>06    |

## 1) 문제 정의

뉴스1 · 6일 전 · 네이버뉴스

### "졸리면 쉬었다 가세요"...수도권 고속도로 내 사망 사고 증가

올해 들어 수도권 고속도로 교통사고 사망자가 크게 증가한 가운데, 졸음운전과 주시태만이 주요 원인으로 지목되면서 운전자들의 각별한 주의가... 한편 연도별 전국 고속도로 사고 사망자 수는 2021년 171명, 2022년 156명, 2023년 150명, 2024...



뉴스타운 · 1주 전

### 계룡소방서, 봄철 나들이객 졸음운전 주의 당부

도로교통공단 통계에 따르면 졸음운전 교통사고 치사율은 2.6명으로, 전체 교통사고 치사율 평균인 1.4명보다 거의 2배 수준에 달해 다른 사고보다 훨씬 치명적인 것으로 나타났다. 특히 시속 100km로 주행 중인 자동차의 운전자가 약 3초간 전방을 주시...




최근 5년간 국내 졸음운전 사고는 9,500건이 넘었고 사망자만 252명. 기술이 발전함에 따라 운전자 부주의 요소도 늘어남.




기술적 솔루션 제안의 필요성이 대두되었고 이에 따른 IDRS 시스템을 제안하며 본 연구는 일반 grayscale 카메라만으로 6가지 부주의 행동을 통합 분류하는 저비용 솔루션을 제안

## 2) 연구 개요






클래스별 샘플 — bbox = 얼굴 영역



클래스 분포 (3 split)



원본 640×360 → bbox + 20% padding



입력값 크기 224×224 → Grayscale이므로 3channel로 복제

6개 클래스로 SafeDriving이 가장 많고 Train set 기준 일부 클래스는 14분의 1 수준으로 불균형



WeightedRandomSampler와 클래스 가중 손실함수를 사용했고, bbox 영역을 20% 패딩 후 크롭해 행동 단서까지 포함

전처리 결과 (모델 입력)

SafeDriving



Drinking




DangerousDriving



Distracted



SleepyDriving



Yawn



```
Class weights (for CrossEntropyLoss):  
DangerousDriving    weight=0.534  
Distracted          weight=1.188  
Drinking            weight=5.739  
SafeDriving         weight=0.401  
SleepyDriving       weight=2.537  
Yawn                weight=4.536
```


각 클래스별 샘플 수에 따른 가중치 부여

| Model           | Accuracy | F1 (macro) | AUC    |
|-----------------|----------|------------|--------|
| HOG + SVM       | 0.9117   | 0.8690     | 0.9814 |
| EfficientNet-B0 | 0.9675   | 0.9603     | 0.9972 |
| ViT-Small       | 0.9756   | 0.9716     | 0.9988 |

Accuracy, F1(macro), AUC의 평가지표 상 ViT-Small 모델이 EfficientNet-B0 모델보다 근소 우위를 점하는 모습이지만 미세한 차이가 중요한 의미를 갖는 지는 알 수 없음



도메인 특화 평가의 필요성이 부각됨.



## 1) Risk-weighted Cost

$$\text{cost}(\text{true} = i, \text{pred} = j) = \begin{cases} 0 & i = j \quad (\text{정답}) \\ \max(1, \text{risk}(i) - \text{risk}(j) + 1)^2 & i \neq j \end{cases}$$

$$\text{Risk-weighted Score} = 1 - \frac{\sum_{n=1}^N \text{cost}(y_n, \hat{y}_n)}{\text{max\_cost} \times N}$$

| Model           | Total Cost | Risk Score | 오분류 수 | 평균 cost/오분류 |
|-----------------|------------|------------|-------|-------------|
| HOG + LinearSVC | 418        | 0.9735     | 87    | 4.81        |
| EfficientNet-B0 | 101        | 0.9936     | 32    | 3.16        |
| ViT-Small       | 75         | 0.9952     | 30    | 2.50        |

ViT는 EffNet의 정확도는 약 1%p 차이지만, 안전 비용은 26% 더 낮음  
→ 오분류의 방향이 다르다



## 1) Risk-weighted Cost

자주 혼동되는 쌍 (Top 8):


| True          | → Predicted        | Count | Cost |
|---------------|--------------------|-------|------|
| SafeDriving   | → Distracted       | 8     | 1    |
| Distracted    | → SafeDriving      | 6     | 9    |
| SafeDriving   | → SleepyDriving    | 4     | 1    |
| Distracted    | → SleepyDriving    | 2     | 1    |
| SafeDriving   | → Drinking         | 2     | 1    |
| SleepyDriving | → Distracted       | 1     | 4    |
| SafeDriving   | → DangerousDriving | 1     | 1    |

ViT-Small의 클래스 별 오분류 패턴 분석

Total Cost의 72%가 "Distracted ↔ SafeDriving" 축에 집중(총 75점 중 62점)

grayscale 카메라가 동공 위치나 시선 방향 등을 제대로 잡지 못하는 한계

## 2) Grad-CAM 해석성



***EfficientNet-B0 Grad-CAM → “국소적 집중형 attention”***

**결정적 단서(휴대폰, 컵, 입)에 집중 → *Local receptive field***



## 2) Grad-CAM 해석성

ViT-Small — Grad-CAM (정답 케이스)



*ViT-Small Grad-CAM* → “광역적 분산형 *attention*”

얼굴 전체 + 자세 + 배경까지 종합해서 분석하려는 *Self-attention*

| Threshold | Coverage | Accuracy |
|-----------|----------|----------|
| 0.50      | 97.4%    | 0.9802   |
| 0.70      | 26.5%    | 0.9617   |
| 0.80      | 24.6%    | 0.9917   |
| 0.90      | 10.7%    | 1.0000   |
| 0.95      | 5.1%     | 1.0000   |
| 0.99      | 0.0%     | nan      |

신뢰도 기반 분석 표

| Model           | Params | 가중치 크기  | Epoch당 학습시간 (12k) | 추정 추론시간/프레임 |
|-----------------|--------|---------|-------------------|-------------|
| HOG + LinearSVC | —      | ~수 MB   | 약 5분 (CPU)        | < 5 ms      |
| EfficientNet-B0 | 5.3 M  | ≈ 21 MB | 약 91 s            | ≈ 7~8 ms    |
| ViT-Small       | 22 M   | ≈ 85 MB | 약 146 s           | ≈ 11~13 ms  |

ViT-Small 기준 **약 90fps**의 성능을 보임 → 임베디드 환경에서 원활한 예측 수행 가능

Stage 1에 ViT-Small 모델을 채택하며 2%의 정확도를 시계열 누적 및 Sensor Fusion을 통해 해결



Stage 2에서 자동으로 처리하지 못한 나머지 2.6%를 차회 프레임 수를 대기하면서 예측 보류하는 식으로 진행



## ① 정량적 발견

단일 grayscale 카메라만으로 6-class 통합 운전자 부주의 분류를 수행하는 IDRS 시스템을 제안함.

HOG+SVM · EfficientNet-B0 · ViT-Small 세 패러다임을 동일 조건에서 비교하여 두 딥러닝 모델은 약 **6%p** 향상된 정확도를 보임.

또한 안전에 직결되는 클래스 부분을 살펴보며 모델의 강점을 보임.

## ② 다층 평가 프레임워크 제안

단순 Accuracy 와 같은 평가 지표에 그치지 않고 Risk-weighted Cost ·

Realiabilty Diagram ·

Grad-CAM를 제시하며 다층 평가 프레임워크를 제시함.

미세한 간극의 차이를 위험도 가중치 분석을 통해 모델이 어떤 방향으로 오분류하는가 안전 비용에 결정적인 요인을 분석하며 결과를 입증함.

## ③ 의의 및 확장 가능성

저비용 단일 카메라 기반 IDRS의 배포 가능성과 한계를 동시에 입증하였고, 향후 멀티모달 융합과 시계열 모델링을 통해 실제 차량 배포 수준의 안전성으로 발전할 토대를 마련함.

더 나아가 본 연구에서 제시한 위험도 가중평가 프레임워크는 다른 도메인에도 일반화 적용될 수 있을 것으로 기대할 수 있음.



인공지능공학과  
12223552 서지민

Thank you

인하대학교  
TERM Project



인하대학교  
INHA UNIVERSITY